

Identifikation und Vergleich von Autorenangaben zu Software zwischen verschiedenen Datenquellen

Wismar, 30. Januar 2025

Fakultät für Ingenieurwissenschaften, Hochschule Wismar

Kevin Jahrens

E-Mail: k.jahrens@stud.hs-wismar.de



Gliederung

- 1 Einleitung
- 2 Grundlagen
- 3 Methodik
- 4 Ergebnisse
- 5 Diskussion

Einleitung

Motivation

- Software spielt zentrale Rolle in der Wissenschaft
- Zitation wesentlicher Bestandteil in wissenschaftlicher Publikation
- Bei wissenschaftlicher Software ist dies in diesem Umfang aktuell nicht gegeben
- Softwareautoren werden nicht immer genannt und manchmal sogar ihrer Beiträge beraubt [2]

Vorgehen

- Autoren aus unterschiedlichen Quellen extrahieren
- Autoren untereinander abgleichen
- Ausschließliche Betrachtung von Autoren, die Code in Git beigetragen haben
- Ergebnisse aufbereiten
- Beantwortung von Forschungsfragen

Forschungsfragen

- F1** Wie gut können Autoren untereinander abgeglichen werden?
- F2** Was muss ein Softwareentwickler leisten, um als Autor genannt zu werden?
- F3** Wie gut werden Autoren in den einzelnen Quellen gepflegt?

Grundlagen

Prinzipien der Software-Zitation [3]

1. **Wichtigkeit:** Software sollte ein seriöses und zitierbares Produkt wissenschaftlicher Arbeit sein.
2. **Anerkennung und Zuschreibung:** Softwarezitate sollten die wissenschaftliche Anerkennung und die normative, rechtliche Würdigung aller Mitwirkenden an der Software ermöglichen.
3. **Eindeutige Identifikation:** Ein Softwarezitat sollte eine Methode zur Identifikation enthalten, die maschinell verwertbar, weltweit eindeutig und interoperabel ist.
4. **Persistenz:** Eindeutige Identifikatoren und Metadaten, die die Software und ihre Verwendung beschreiben, sollten bestehen bleiben – auch über die Lebensdauer der Software hinaus.
5. **Zugänglichkeit:** Softwarezitate sollten den Zugang zur Software selbst und weiteren Materialien erleichtern, um sie sachkundig nutzen zu können.
6. **Spezifizität:** Softwarezitate sollten die Identifikation und den Zugang zu der spezifischen Version der verwendeten Software erleichtern. Die Identifizierung der Software sollte so spezifisch wie nötig sein.


Versionsverwaltung

- Verwaltet Quellcode und dessen Änderungen in einem Repository
- Git ist eine weit verbreitete Versionsverwaltung mit einem Marktanteil von ungefähr 75 % [1]
- Speichert Zeitpunkt und Autor, sowie die Änderungen in einem Commit
- Name und E-Mail des Autors frei wählbar
- In Git werden weitere Daten gespeichert, welche ausgelesen werden können:
 - Anzahl der eingefügten und gelöschten Zeilen
 - Anzahl der geänderten Dateien
 - Anzahl der Commits
- Repositories können auf einem Server verwaltet werden
- Weit verbreiteter Anbieter eines Git-Servers ist GitHub

Software-Verzeichnisse und Paketverwaltung

- Eine Paketverwaltung verwaltet fertige Softwarepakete, bspw. kompilierten Code
- Softwarepakete können in einem Software-Verzeichnis abgelegt werden
- Softwarepakete enthalten Metadaten, bspw. die Autoren des Pakets
- Es werden die Verzeichnisse PyPI (Python) und CRAN (R) untersucht
- Für beide Verzeichnisse stehen APIs zur Verfügung, welche die Metadaten bereitstellen

Zitierformat – Citation File Format

- Wird als Datei z. B. in einem Git-Repository gespeichert
- Auf GitHub  verwaltet
- 2.512 Repositorys auf GitHub haben eine CFF-Datei (Stand 07.11.2024)
- Dient dazu anderen die Zitation der Software zu erleichtern
- Kann unter anderem durch Programme wie *cffinit* erstellt werden [5]
- *cffconvert* bietet die Möglichkeit der Validation und der Umwandlung z. B. in BibT_EX [4]

```
1  cff-version: 1.2.0
2  title: "CompAuthorsBetweenDS"
3  message: "If you use this software, please cite it
   ↪ using the metadata from this file."
4  type: software
5  authors:
6    - given-names: "Kevin"
7      family-names: "Jahrens"
8      email: "k.jahrens@stud.hs-wismar.de"
9    - name: "Hochschule Wismar"
10 preferred-citation:
11   title: "Identifikation und Vergleich von
   ↪ Autorenangaben zu Software zwischen
   ↪ verschiedenen Datenquellen"
12 type: thesis
13 year: 2025
14 authors:
15   - given-names: "Kevin"
16     family-names: "Jahrens"
17     email: "k.jahrens@stud.hs-wismar.de"
18   - name: "Hochschule Wismar"
```

Zitierformat – BibT_EX

- Software, zur Erstellung von Literaturangaben und -verzeichnissen in L^AT_EX-Dokumenten
- Gleichnamiges Format, wird als Datei z. B. in einem Git-Repository gespeichert
- 2.144 Repositorys auf GitHub haben eine BibT_EX-Datei (Stand 07.11.2024)
- Kein offizieller Literaturtyp für Software
- Kann unter anderem durch Programme wie Zotero erstellt werden [6]
- Felder vom Literaturtyp abhängig

```
1 @masterthesis{Jahrens:2025,  
2   author = {Jahrens, Kevin},  
3   title = {Identifikation und Vergleich von  
4     ↪ Autorenangaben zu Software zwischen  
5     ↪ verschiedenen Datenquellen},  
6   school = {Hochschule Wismar},  
7   month = {1},  
8   year = {2025}  
9 }
```

Named Entity Recognition

- Beschreibt den Prozess der automatischen Erkennung und Klasseneinteilung von Substantiven (Entitäten) im Text
- Typische Entitäten sind Personen, Orte oder Organisationen
- Viele Anwendungsgebiete bspw. Informationsextraktion aus Texten

Pytorch README

PyTorch (Organisation) *is currently maintained by* **Soumith Chintala** (Person), **Gregory Chanan** (Person), **Dmytro Dzhulgakov** (Person), **Edward Yang** (Person), and **Nikita Shulga** (Person) *with major contributions coming from* **hundreds** (Digit) *of talented individuals in various forms and means.*

Unscharfe Suche

- Findet ähnliche Zeichenfolgen, die sich in ihrer Schreibweise unterscheiden
- Als Ergebnis wird zumeist eine Distanz zwischen zwei Zeichenfolgen in Prozent angegeben
- Viele Anwendungsgebiete bspw. die Suche eines Namens in einem Index

Unscharfe Suche

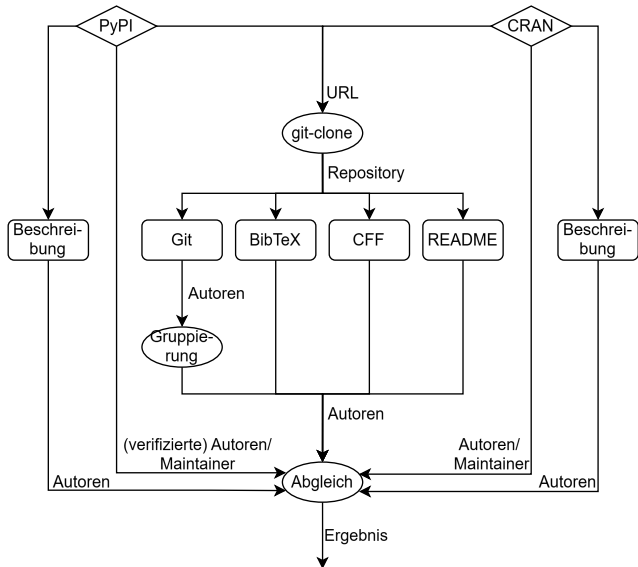
Soumith Chintala \leftrightarrow Soumith **S.** Chintala: 91 %

Soumith Chintala \leftrightarrow **Su**omith Chintala: 94 %

Methodik

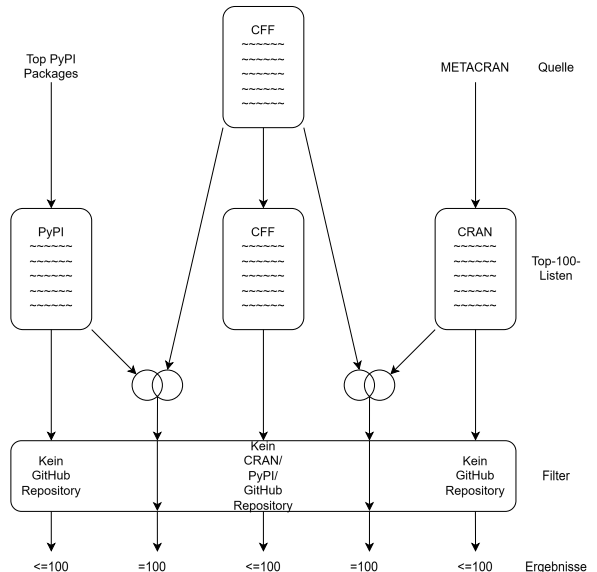
Datenbeschaffung

- Datenbeschaffung für jeweils ein Paket (PyPI oder CRAN)
- Git, BibTeX, CFF und README werden zu Änderungszeitpunkten beschafft
- Beschreibung und README setzt NER ein



Top-100-Listen

- 5 Top-100-Listen wurden erstellt und untersucht:
 1. Top-100 PyPI
 2. Top-100 CRAN
 3. Top-100 CFF
 4. Top-100 PyPI CFF
 5. Top-100 CRAN CFF
- Top-100 definiert an der Anzahl der Downloads (PyPI, CRAN) bzw. Sterne (CFF) auf GitHub



Abgleich

- Abgleich jeweils zwischen Git und einer weiteren Quelle
- Vereinfachung: Abgleich der Git-Autoren des aktuellen Stands mit den Quellen
- Abgleich verwendet Python *in* und die unscharfe Suche
- Abgleich erfolgt anhand:
 - Name
 - E-Mail
 - Benutzername
- Für jeden Vergleich zweier Autoren wird ein Score berechnet
- Die Kombination mit dem besten Score wird ausgewählt
- Autoren mit mehr Commits werden bevorzugt

Ergebnisse

Diskussion

Literaturverzeichnis

- [1] Jannik Lindner. *Version Control Systems Industry Statistics*. 3. Mai 2024. URL: <https://worldmetrics.org/version-control-systems-industry-statistics/> (besucht am 21.05.2024).
- [2] Ariel Miculas. *How I got robbed of my first kernel contribution*. 27. Sep. 2023. URL: <https://ariel-miculas.github.io/How-I-got-robbed-of-my-first-kernel-contribution/> (besucht am 03.06.2024).
- [3] Arfon M. Smith, Daniel S. Katz und Kyle E. Niemeyer. „Software citation principles“. In: *PeerJ Computer Science* 2 (19. Sep. 2016), e86. DOI: [10.7717/peerj-cs.86](https://doi.org/10.7717/peerj-cs.86).
- [4] Jurriaan H. Spaaks u. a. *cffconvert*. 22. Sep. 2021. DOI: [10.5281/zenodo.5521767](https://doi.org/10.5281/zenodo.5521767).
- [5] Jurriaan H. Spaaks u. a. *cffinit*. 8. Aug. 2023. DOI: [10.5281/zenodo.8224012](https://doi.org/10.5281/zenodo.8224012).
- [6] Zotero. *Zotero | Your personal research assistant*. 2024. URL: <https://www.zotero.org/> (besucht am 01.10.2024).